

Блок 1. Эмпирическая функция распределения и плотность показателя X

Математическое обоснование

1. **Я выбрал это потому что** эмпирическая функция распределения (ЭФР) и ядерная оценка плотности (KDE) являются фундаментальными инструментами непараметрического анализа случайных величин. Согласно теореме Гливенко — Кантелли, эмпирическая функция $F_{n(x)}$ равномерно сходится с вероятностью 1 к истинной теоретической функции распределения $F(x)$ при $n \rightarrow \infty$. График плотности, в свою очередь, позволяет визуальнo зафиксировать модальность, асимметрию и «тяжесть» хвостов распределения, что критически важно для подбора теоретической модели распределения доходов.
2. **Я сделал это так потому что** классическая гистограмма дискретна и ее форма сильно зависит от шага группировки (bins). Чтобы уйти от этой субъективности, я применил метод ядерного сглаживания (Kernel Density Estimation) с гауссовым ядром вида:

$$\hat{f}_{h(x)} = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right)$$

где h — ширина полосы сглаживания. График ЭФР построен в виде точной ступенчатой функции с шагом $\frac{1}{n}$ в точках локализации вариант выборки, что исключает потерю информации о структуре данных.

Как работает код

- Функция `sns.histplot(df[X_col], kde=True, stat="density")` нормирует площадь гистограммы так, чтобы она была равна 1 (переход от абсолютных частот к плотности вероятности), и накладывает поверх сглаженную кривую KDE.
- Функция `sns.ecdfplot` автоматически ранжирует вариационный ряд и строит монотонно неубывающую функцию, отображающую накопленную вероятность $P(X \leq x)$.

Блок 2. Проверка гипотезы о нормальном распределении значений показателя X

Математическое обоснование

1. **Я выбрал одновыборочный критерий Колмогорова — Смирнова потому что** он является одним из самых известных и классических (базовых) непараметрических критериев согласия. В отличие от узкоспециализированного теста Шапиро-Уилка, критерий Колмогорова-Смирнова более универсален и геометрически нагляден: он проверяет гипотезу о принадлежности анализируемой выборки к заданному теоретическому закону (в нашем случае — к нормальному распределению) путем прямого сравнения их функций распределения.
2. **Я сделал это так потому что** математически статистика критерия D вычисляется как супремум (максимальное абсолютное вертикальное отклонение) между эмпирической функцией распределения $F_{n(x)}$ и теоретической функцией распределения нормального закона $F(x)$:

$$D = \sup_x |F_n(x) - F(x)|$$

Теоретическая функция $F(x)$ инициализируется параметрами, которые мы оцениваем по самой выборке (выборочным средним $|X|$ и стандартным отклонением s). Если

максимальная дистанция D слишком велика, то вероятность получить такое расхождение случайно крайне мала ($p\text{-value} < \alpha$), и мы отвергаем нулевую гипотезу H_0 о нормальности распределения доходов.

Как работает код

- Мы предварительно вычисляем параметры распределения: выборочное среднее `mean()` и стандартное отклонение `std()`, чтобы “подогнать” теоретическую нормальную кривую под наши данные.
 - Функция `stats.kstest(df[X_col], 'norm', args=(mean_val, std_val))` накладывает эмпирическую функцию на теоретическую, находит точку их максимального расхождения и возвращает значение статистики D , а также соответствующее ей $p\text{-value}$.
 - Логический блок сравнивает полученное $p\text{-value}$ с установленным порогом ошибки первого рода $\alpha = 0.05$, автоматически формируя статистический вывод.
-

Блок 3. Проверка гипотезы о равенстве математических ожиданий

Математическое обоснование

1. **Я выбрал t-критерий Уэлча (модификацию критерия Стьюдента) потому что** исследуемые подвыборки Группы А (неблагонадежные заемщики, $Y = 0$) и Группы Б (благонадежные заемщики, $Y = 1$) имеют существенно разные объемы и, что важнее, разные внутригрупповые дисперсии (гетероскедастичность). Классический тест Стьюдента в условиях нарушенной гомоскедастичности приводит к сильному смещению ошибки первого рода. Критерий Уэлча использует модифицированный расчет стандартной ошибки и аппроксимирует число степеней свободы по формуле Саттертуэйта:

$$\nu \approx \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2} \right)^2}{\frac{s_1^4}{n_1^2(n_1-1)} + \frac{s_2^4}{n_2^2(n_2-1)}}$$

2. **Я сделал это так потому что** мы проверяем строгую двухстороннюю гипотезу о равенстве центров распределений. Статистика критерия t показывает, на сколько стандартных ошибок разность выборочных средних $(|X|_A - |X|_B)$ удалена от нуля.

Как работает код

- Конструкция `df[df[Y_col] == 0][X_col]` осуществляет логическую фильтрацию (маскирование) исходного фрейма данных, разделяя вектор доходов по категориальному маркеру Y .
 - В функции `stats.ttest_ind` ключевой параметр `equal_var=False` отключает предположение о равенстве дисперсий, переключая алгоритм на формулу Уэлча.
-

Блок 4. Проверка гипотезы о равенстве распределений

Математическое обоснование

1. **Я выбрал двухвыборочный критерий Колмогорова — Смирнова потому что он** является мощным непараметрическим методом проверки гипотезы об однородности двух независимых выборок. Финансовые показатели (такие как месячные платежи по кредитам) практически никогда не подчиняются нормальному закону распределения из-за выраженной асимметрии и тяжелых хвостов. Использование непараметрического

критерия позволяет избежать жестких требований к нормальности данных и равенству дисперсий (гомоскедастичности), гарантируя математическую строгость выводов.

Мы проверяем следующие статистические гипотезы:

- $H_0 : F_{A(x)} = F_{B(x)}$ (Распределения месячных платежей в группах до 35 лет и старше 35 лет идентичны, выборки однородны).
- $H_1 : F_{A(x)} \neq F_{B(x)}$ (Распределения месячных платежей в группах значимо различаются, выборки неоднородны).

2. **Я сделал это так потому что** критерий Колмогорова — Смирнова оценивает расхождение между распределениями через сравнение их эмпирических функций накопленных вероятностей $F_{A(x)}$ и $F_{B(x)}$. Статистика критерия D представляет собой точную верхнюю грань (супремум) абсолютного расстояния между этими функциями во всех точках измерения:

$$D = \sup_x |F_{A(x)} - F_{B(x)}|$$

При справедливости нулевой гипотезы величина расхождения D , масштабированная объемом выборок, асимптотически стремится к распределению Колмогорова. Если вычисленный супремум разности D оказывается больше критического порога (что соответствует достигнутому уровню значимости $p\text{-value} < \alpha$), нулевая гипотеза отвергается.

Как работает код

Для проведения анализа на Python используется библиотека `scipy.stats`. Процесс вычислений состоит из следующих этапов:

- **Сегментация данных:** На основе вектора возраста заемщиков исходный массив месячных платежей фильтруется на две изолированные группы:

```
group_A_payment = df[df['Возраст'] < 35]['Месячный платеж (тыс.руб.)'].dropna()
group_B_payment = df[df['Возраст'] >= 35]['Месячный платеж (тыс.руб.)'].dropna()
```

Использование метода `.dropna()` обязательно для корректной работы математического ядра библиотеки, чтобы исключить пропуски из расчетов.

- **Вычисление статистики:** Функция `stats.ks_2samp(group_A, group_B)` автоматически строит дискретные ступенчатые эмпирические функции распределения для обеих групп, находит точку x , в которой вертикальное расстояние между графиками максимально, фиксирует эту величину как статистику D и рассчитывает вероятность ошибки первого рода $p\text{-value}$.

Результаты статистического теста

По результатам обработки эмпирических данных были получены следующие параметры:

- Размер Группы А (возраст < 35): $n_A = 506$
- Размер Группы Б (возраст >= 35): $n_B = 493$
- Статистика критерия Колмогорова-Смирнова: $D = 0.0558$
- Достигнутый уровень значимости: $p\text{-value} = 3.9788 \times 10^{-1}$ (или 0.3979)

Так как вычисленное значение $p\text{-value} \approx 0.40$ значительно больше установленного уровня значимости $\alpha = 0.05$, у нас **нет оснований отвергнуть нулевую гипотезу H_0** .

Блок 5. Проверка гипотезы о независимости двух категориальных переменных

Математическое обоснование

1. **Я выбрал критерий независимости Хи-квадрат (χ^2) Пирсона потому что обе анализируемые переменные («Благонадежность заемщика» и «Наличие иждивенцев») переведены в номинальную (категориальную) шкалу с бинарным исходом (0 или 1). В данной шкале невозможно использовать линейные коэффициенты корреляции. Математическая суть критерия заключается в проверке мультипликативного свойства вероятностей независимых событий: если факторы независимы, то теоретическая вероятность попадания в ячейку таблицы сопряженности равна произведению маргинальных вероятностей. Статистика оценивает нормированное отклонение наблюдаемых частот (O_{ij}) от теоретически ожидаемых (E_{ij}):**

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

2. **Я сделал это так потому что распределение данной статистики при увеличении объема выборки асимптотически стремится к распределению Хи-квадрат со степенью свободы $dof = (r - 1)(c - 1)$. При размерности таблицы 2×2 число степеней свободы строго равно 1.**

Как работает код

- Функция `pd.crosstab(df['Есть_иждивенцы'], df[Y_col])` строит матрицу сопряженности, подсчитывая количество объектов на пересечении каждого фактора.
- Функция `stats.chi2_contingency` принимает матрицу, вычисляет ожидаемые частоты E_{ij} , рассчитывает итоговую сумму отклонений χ^2 и определяет p -value по плотности распределения Хи-квадрат с одной степенью свободы.